

Trabalho computacional - Política de Manutenção

Cleyton Nobre

Universidade Federal de Minas Gerais
Belo Horizonte/MG - Brasil
cleyton-nobre@ufmg.br

Thales Tenebra

Universidade Federal de Minas Gerais
Belo Horizonte/MG - Brasil
thalestenebra@ufmg.br

Thiago Fraga

Universidade Federal de Minas Gerais
Belo Horizonte/MG - Brasil
thi-fraga@ufmg.br

Abstract—Este trabalho aplica conceitos de Teoria da Decisão na definição de uma política ótima de manutenção para 500 equipamentos de uma empresa, buscando minimizar os custos de manutenção e os custos esperados de falha. O problema é modelado com base em dados reais e resolvido por meio de meta-heurísticas adaptadas, tanto em abordagens mono quanto multiobjetivo. A análise considera modelos de falha específicos por grupo de equipamentos e diferentes planos de manutenção. A escolha da melhor solução é feita com apoio de métodos multicritério e avaliação por hipervolume.

I. INTRODUÇÃO

A manutenção de equipamentos industriais é um fator crítico para a operação eficiente e segura de uma empresa. Decisões mal planejadas podem resultar em custos elevados, seja pela falha inesperada de ativos importantes ou pelo excesso de intervenções desnecessárias. Neste contexto, a otimização multi-objetivo oferece ferramentas fundamentais para apoiar o processo de escolha das melhores estratégias de manutenção, considerando múltiplos critérios e incertezas envolvidas.

Este trabalho computacional tem como objetivo aplicar os conceitos estudados na disciplina Teoria da Decisão à formulação e resolução de um problema de otimização relacionado à definição da política de manutenção de 500 equipamentos. A proposta envolve a construção de modelos matemáticos de otimização mono e multiobjetivo, implementação de algoritmos baseados em metaheurísticas e a aplicação de métodos multicritério para apoiar a escolha da melhor solução. O desempenho das abordagens propostas é avaliado por meio do indicador de hipervolume, que permite medir a qualidade das soluções obtidas em termos de convergência e diversidade.

Na Seção II apresentaremos a modelagem matemática do problema. Na qual é descrita a equação que o algoritmo otimizará, além da formulação matemática dos métodos de otimização.

Na Seção III é apresentada a modelagem do problema multiobjetivo utilizando o método da soma ponderada, transformando o problema multi em mono-objetivo.

A Seção IV traz a modelagem do problema multi-objetivo utilizando o método ε -restrito. Que utiliza do método das penalidade para transformar um problema de otimização restrito, em um problema irrestrito.

Na Seção VI, é apresentada a metodologia adotada para o desenvolvimento deste trabalho. São descritos os procedimentos utilizados, e as ferramentas aplicadas durante o desenvolvimento do trabalho.

A apresenta a formulação do método de avaliação da fronteira de pareto que será retornada pelos algoritmos desenvolvidos.

A Seção VII traz os resultados obtidos a partir da aplicação da metodologia, acompanhados de análises e interpretações relevantes para a compreensão do desempenho e da validade da proposta.

Por fim, na Seção VIII, são discutidas as conclusões do estudo, destacando as principais contribuições, limitações e sugestões para trabalhos futuros.

II. MODELAGEM MATEMÁTICA

A seguir, apresenta-se a modelagem matemática utilizada para o planejamento de manutenção preventiva de um conjunto de equipamentos, considerando custos de manutenção e falha ao longo de um horizonte de tempo pré-definido.

A. Conjuntos e Parâmetros

- $J = \{1, 2, 3\}$: Planos de manutenção ($j \in J$)
- I : Conjunto de equipamentos ($|I| = 500$, $i \in I$)
- $C = \{1, 2, 3, 4\}$: Clusters de equipamentos ($c \in C$)
- t_0^i : Idade atual do equipamento i (em anos)
- c_i : Cluster ao qual pertence o equipamento i
- f_i : Custo associado à falha do equipamento i
- k_j : Fator de risco do plano de manutenção j
- m_j : Custo de aplicar o plano j a um equipamento
- η_c : Parâmetro de escala (Weibull) para o cluster c
- β_c : Parâmetro de forma (Weibull) para o cluster c
- $p_{i,j}$: Probabilidade de falha do equipamento i sob o plano de manutenção j
- $\Delta t = 5$ anos: Horizonte de planejamento

B. Variável de decisão

$$x_{i,j} = \begin{cases} 1, & \text{se o equipamento } i \text{ realiza a manutenção } j \\ 0, & \text{Caso contrário} \end{cases} \quad (1)$$
$$\forall i \in I, \forall j \in J$$

C. Funções objetivo

$$f_1(\hat{x}) = \min \sum_{i \in I} \sum_{j \in J} m_j \cdot x_{i,j} \quad (\text{Custo total de manutenção}) \quad (2)$$

$$f_2(\hat{x}) = \min \sum_{i \in I} \sum_{j \in J} p_{i,j} \cdot x_{i,j} \cdot f_i \quad (\text{Custo esperado de falha}) \quad (3)$$

onde:

$$p_{i,j} = \frac{F_{c_i}(t_0^i + k_j \Delta t) - F_{c_i}(t_0^i)}{1 - F_{c_i}(t_0^i)} \quad (4)$$

$$F_{c_i}(t) = 1 - e^{-\left(\frac{t}{\eta_c}\right)^{\beta_c}} \quad (5)$$

D. Surjeito a:

$$\sum_{j \in J} x_{i,j} = 1 \quad \forall i \in I \quad \text{Integridade} \quad (6)$$

III. FORMULAÇÃO DA SOMA PONDERADA (P_w)

A abordagem da soma ponderada transforma um problema com múltiplos objetivos em um único problema escalar, por meio de uma combinação linear das funções objetivo.

A. *Problema Original*

Funções objetivos:

$$f_k(\hat{x}) \quad \forall k \in \{1, 2, \dots, n\} \quad (7)$$

Sujeito a:

$$g_j(\hat{x}) \leq 0 \quad \forall j \quad (8)$$

$$h_l(\hat{x}) = 0 \quad \forall l \quad (9)$$

$$\hat{x} \in \mathbb{R}^D \quad (10)$$

Onde:

- $\hat{x}$ é o vetor de decisão.
- n é o numero de funções objetivo.
- $f_k(\hat{x})$ são as funções objetivo.
- $g_j(\hat{x})$ e $h_l(\hat{x})$ é o conjunto de restrições.
- Sendo $\mathbb{D}$ a dimensão de $\hat{x}$.

B. *Formulação da Soma Ponderada*

Minimizar:

$$F(x) = \sum_{i=1}^n w_i \cdot \hat{f}_i(x) \quad (11)$$

Sujeito a:

$$g_j(\hat{x}) \leq 0 \quad \forall j \quad (12)$$

$$h_l(\hat{x}) = 0 \quad \forall l \quad (13)$$

$$\sum_{i=1}^n w_i = 1 \quad (14)$$

$$w_i \geq 0, \forall i \quad (15)$$

C. *Normalização*

$$\hat{f}(\hat{x}) = \frac{f(\hat{x}) - \min f(\hat{x})}{\max f(\hat{x}) - \min f(\hat{x})} \quad (16)$$

Essa normalização é necessária para garantir que os objetivos estejam na mesma escala antes da aplicação da soma ponderada.

D. *Interpretação*

Os pesos w_i definem a importância relativa de cada objetivo. Ao variar os pesos, é possível gerar diferentes soluções de compromisso. A abordagem da soma ponderada pode não encontrar soluções em regiões não convexas do fronte de Pareto. A formulação por soma ponderada é simples e eficiente para problemas com fronte de Pareto convexo, permitindo controle sobre os trade-offs entre objetivos via pesos.

IV. FORMULAÇÃO ε -RESTRITO (P_ε)

A abordagem ε -restrita transforma um problema multiobjetivo em um problema de otimização com uma única função objetivo, tratando os demais objetivos como restrições com limites ε_i . Para transformar o problema descrito em Seção III.A em um problema possível de ser resolvido pelo método de ε -restrito seguimos os seguintes passos:

A. *Formulação ε -Restrita*

Função objetivo:

$$\min f_k(\hat{x}) \quad (17)$$

Sujeito a:

$$f_i(\hat{x}) \leq \varepsilon_i \quad \forall i \in \{1, \dots, n\} \quad i \neq \{k\} \quad (18)$$

$$g_j(\hat{x}) \leq 0 \quad \forall j \quad (19)$$

$$h_l(\hat{x}) = 0 \quad \forall l \quad (20)$$

Onde:

- $f_k(\hat{x})$ é o objetivo escolhido para otimização.
- Os demais objetivos $f_i(\hat{x})$ são tratados como restrições com limites ε_i .

V. FORMULAÇÃO DO HIPERVOLUME

O Hipervolume é um indicador de qualidade, também conhecido como s-metric, sendo amplamente utilizado em otimização multiobjetivo para avaliar a qualidade de um conjunto de soluções não-dominadas. Ele é capaz de mensurar simultaneamente convergência e diversidade das soluções.

Seja:

- P = conjunto de soluções não dominadas
- r = vetor de referência anti-utópico (nadir)
- $f(x)$ = vetor dos objetivos para a solução x

O hipervolume (HV) é definido como:

$$HV(P) = \text{vol} \left(\bigcup_{x \in P} \prod_{i=1}^m [f_i(x), r_i] \right) \quad (21)$$

VI. METODOLOGIA

O presente trabalho tem como objetivo propor uma abordagem baseada em heurísticas para a alocação de planos de manutenção preventiva em equipamentos, considerando os custos envolvidos e o risco de falha, utilizando o algoritmo meta-heurístico GVNS.

O General Variable Neighborhood Search (GVNS) é uma meta-heurística avançada baseada no método Variable Neighborhood Search (VNS), projetada para resolver problemas complexos de otimização combinatória. Ele explora sistematicamente diferentes estruturas de vizinhança para escapar de ótimos locais e encontrar soluções de melhor qualidade.

Partido do pré-suposto acima o trabalho foi estruturado da seguinte conforme as seguintes etapas:

A. *Leitura e Pré-processamento dos Dados*

Para a resolução do problema foram carregados, três bases de dados, sendo elas:

- EquipDB.csv: contém o ID do equipamento, o tempo desde a última falha, o cluster ao qual pertence e o custo associado à falha.
- ClusterDB.csv: fornece os parâmetros da distribuição de Weibull (η e β) por cluster.
- MPDB.csv: lista os planos de manutenção com seus respectivos fatores de risco (k) e custos.

B. Modelagem Probabilística de Falha

Foi utilizada a função de distribuição acumulada de Weibull para calcular a probabilidade de falha acumulada $F(t)$ equação (5) e a probabilidade condicional de falha $P(t_0, \eta, \beta, k, \Delta t)$ Equação (4), com base no tempo desde a última falha, nos parâmetros da distribuição e no fator de risco de cada plano.

Para cada equipamento i e plano j , foi calculada a probabilidade condicional de falha utilizando a fórmula de Weibull fornecida nas equações (4), (5). Esses valores foram armazenados em uma matriz P_{ij} , representando o risco de falha caso o plano j seja aplicado ao equipamento i .

Na qual a distribuição Weibull é uma distribuição de probabilidade contínua muito usada em análise de confiabilidade, análise de sobrevivência, e em engenharia para modelar o tempo até a falha de um sistema ou componente.

C. Geração de Solução Inicial

Para alcançar uma convergência mais rápida um solução inicial X foi gerada utilizando um critério de criticidade, definido como o produto entre o custo de falha, a probabilidade de falha e o tempo desde a última falha. Dessa forma, os equipamentos foram ordenados por criticidade, e os planos de manutenção foram atribuídos da seguinte forma:

- 20% mais críticos: plano mais detalhado.
- 30% intermediários: plano médio.
- 50% menos críticos: sem manutenção.

D. Definição das Funções Objetivo

Partido da formulação matemática do problema duas funções objetivo foram consideradas:

- f_1 : Equação (2) minimiza o custo total de manutenção preventiva.
- f_2 : Equação (3) minimiza o custo esperado de falha, calculado como o produto entre a probabilidade de falha e o custo de falha.

E. Estrutura de Vizinhança

Três operadores de vizinhança foram implementados:

- move: altera aleatoriamente o plano de um equipamento.
- double_move: altera os planos de dois equipamentos distintos.
- block_change: altera os planos de um bloco de até 50 equipamentos consecutivos.

F. Heurística GVNS (General Variable Neighborhood Search)

A busca GVNS foi aplicada para cada função objetivo. A abordagem consiste em:

- 1) Gerar uma solução inicial baseada na criticidade.

- 2) Aplicar uma sequência de vizinhanças.
- 3) Realizar busca local a partir da vizinhança explorada.
- 4) Atualizar a solução caso haja melhoria.
- 5) Repetir por um número fixo de iterações.

G. Otimização via soma ponderada

A abordagem utilizada para aplicar a soma ponderada na resolução do problema multiobjetivo consistiu nos seguintes passos:

- 1) Seleção aleatória de um valor de $w \in [0, 1]$, representando o peso atribuído à função objetivo de custo de manutenção (f_1);
- 2) Normalização das funções f_1 e f_2 , de modo a garantir comparabilidade entre grandezas com escalas distintas;
- 3) Construção de uma nova função objetivo agregada por meio da fórmula:

$$F(x) = w \cdot \hat{f}_1(x) + (1 - w) \cdot \hat{f}_2(x) \quad (22)$$

onde $\hat{f}_1(x)$ e $\hat{f}_2(x)$ são as versões normalizadas de f_1 e f_2 , respectivamente;

- 4) Aplicação do algoritmo GVNS para otimizar a função agregada, utilizando as mesmas estruturas de vizinhança e critérios de busca local previamente definidos;

H. Otimização via ε -restrito

A abordagem utilizada para aplicar o método ε -restrito na resolução do problema multiobjetivo consistiu nos seguintes passos:

- 1) Escolha aleatória de uma das funções objetivo (f_1 ou f_2) para ser minimizada na iteração corrente;
- 2) Geração de um valor aleatório de ε dentro do intervalo observado da função que será tratada como restrição;
- 3) Construção de uma nova função objetivo penalizada da forma:

$$F(x) = f_{\min}(x) + \rho \cdot \max\{0, f_r(x) - \varepsilon\} \quad (23)$$

onde:

- $f_{\min}(x)$: representa a função escolhida para minimização (custos de manutenção ou custos de falha),
- $f_r(x)$ é a função tratada como restrição,
- ρ é um coeficiente de penalidade utilizado para penalizar violações da restrição ε ao qual foi escolhido arbitrariamente o valor de 100.

- 4) Aplicação do algoritmo GVNS para otimizar a função penalizada, com as mesmas estruturas de vizinhança e procedimentos de busca local.

I. Avaliação Experimental

Para avaliação do algoritmo GVNS em um problema mono-objetivo, ele foi executado 5 vezes para cada função objetivo (f_1 e f_2). Foram coletadas as seguintes métricas:

- Custo mínimo, máximo e desvio padrão das soluções encontradas.
- Curvas de convergência por iteração.

Para otimização multi objetivo o modelo foi executado 5 vezes com 20 iterações cada para poder encontrar uma fronteira de pareto de pontos no espaço multi-objetivo. A fronteira obtida

em cada um dos métodos foi avaliada de acordo com o seu hipervolume.

VII. RESULTADOS

Por se tratar de um método estocástico, o GVNS não garante a obtenção do ponto ótimo global das funções objetivo. Assim, o algoritmo foi executado 5 vezes para cada função objetivo, possibilitando a obtenção de soluções distintas em cada execução. Para análise dos resultados, foram registrados o menor e o maior valor encontrado, o desvio padrão das soluções obtidas e o gráfico de convergência do algoritmo em cada iteração.

A. Otimização mono-objetivo

Como ponto de referência, o melhor e o pior resultado para f_1 ocorrem, respectivamente, quando não realizamos manutenção em nenhum dos equipamentos — resultando em um custo de \$0 — e quando realizamos manutenção detalhada em todos os equipamentos, o que gera um custo de \$1000

Por sua vez, o melhor e o pior resultado para f_2 ocorrem, respectivamente, quando realizamos manutenção detalhada em todos os equipamentos — resultando em um custo esperado de \$1048,18 — e quando não realizamos manutenção em nenhum deles, o que gera um custo de \$1745,49.

Os resultados obtidos estão apresentados a seguir:

- f_1 : Custo total de manutenção
 - Mínimo: \$28,0
 - Máximo: \$40,0
 - Desvio Padrão: \$4,41
 - Gráfico de convergência:




Fig. 1: Convergência da função $f_1(\hat{x})$ com 5 iterações

- f_2 : Custo esperado de falha
 - Mínimo: \$1061,63
 - Máximo: \$1063,60
 - Desvio Padrão: \$0,65
 - Gráfico de convergência:




Fig. 2: Convergência da função $f_2(\hat{x})$ com 5 iterações

Analisando os resultados obtidos podemos perceber que as soluções encontradas são bastante próximas umas das outras, indicando grande estabilidade no algoritmo. Os gráficos mostram as diversas soluções que o algoritmo encontrou ao longo do seu processo de otimização até atingir um ponto suficientemente ótimo.

B. Fronteira Pareto

A fronteira de Pareto representa o equilíbrio (trade-off) entre o custo de manutenção (f_1) e o custo esperado de falha (f_2). Como o objetivo é minimizar ambos, os pontos mais desejáveis situam-se próximos ao canto inferior esquerdo do gráfico. Observa-se que, para valores baixos de f_1 , os valores de f_2 tendem a ser elevados (em torno de 1700). Abaixo, ilustramos a fronteira de Pareto resultante da otimização utilizando duas formulações distintas: a soma ponderada, descrita na Seção Seção III, e o método ε -restrito, apresentado na Seção Seção IV.

a) Otimização via P_w :

A Figura Fig. 3 ilustra a fronteira de Pareto obtida a partir de cinco repetições da otimização com o algoritmo de soma ponderada. Observa-se que as fronteiras resultantes são bastante próximas entre si, o que indica uma boa consistência do algoritmo.




Fig. 3: Fronteira Pareto otimizada com P_w com 5 repetição

Além de que observamos que medida que o custo de manutenção aumenta, o custo esperado de falha diminui — o que é esperado: investir mais em manutenção reduz as falhas.

A fronteira de Pareto obtida via P_w boa convergência e diversidade nas soluções. Embora não tenha alcançado o ponto ótimo teórico, chegou relativamente próximo, especialmente nas soluções com maior custo de manutenção. Isso mostra que o método é eficaz para capturar o equilíbrio entre os objetivos conflitantes.

Para avaliar a qualidade do conjunto de soluções obtido, utilizamos a relação de hipervolume, descrito na equação (21), como métrica. Essa relação foi calculada a partir da aproximação da área dominada pelas soluções obtidas, ou seja acima da curva de Pareto, em relação à área total delimitada pelos pontos de referência utópico e nadir no espaço dos objetivos. Como resultado, obtivemos um valor de 0,617739, o que significa que aproximadamente 61,77% do espaço potencialmente dominável foi efetivamente coberto pelas soluções não dominadas encontradas.

Esse valor indica uma boa cobertura da frente de Pareto, sugerindo que o algoritmo de otimização conseguiu encontrar soluções bem distribuídas e relativamente próximas da frente ótima teórica.

b) Otimização via P_ε :

A Figura Fig. 4 ilustra a fronteira estimada após 5 repetições do algoritmo usando o método do ε -restrito. É possível observar que as fronteiras obtidas em cada repetição são bastante similares, o que evidencia a robustez do algoritmo proposto.

Com essa figura é possível observar a que a medida que uma das funções é otimizada, a outra tende a aumentar. Com essa figura, é possível observar que, à medida que uma das funções objetivo é minimizada, a outra tende a aumentar — comportamento típico em problemas multiobjetivo com objetivos conflitantes, como é o caso do custo de manutenção e do custo esperado de falha. Isso reforça a coerência da modelagem e da implementação.




Fig. 4: Fronteira Pareto otimizada com P_ε com 5 repetição

A estratégia do ε -restrito mostrou-se eficiente em explorar diferentes regiões da fronteira de Pareto. Por restringir explicitamente uma das funções objetivo em cada execução, o método força o algoritmo a buscar soluções viáveis mesmo em áreas extremas do espaço de decisão, promovendo uma boa diversidade no conjunto final de soluções.

A avaliação do hipervolume foi novamente utilizada como métrica de qualidade, resultando em um valor de 0,638422. Esse valor indica que aproximadamente 63,84% do espaço potencialmente dominável foi coberto pelas soluções não dominadas obtidas. Embora ligeiramente superior ao valor alcançado pelo método P_w , o algoritmo pode variar, já que há uma aleatoriedade na escolha dos pesos de P_w e dos ε s de P_ε .

Portanto, o método P_ε demonstrou ser tão eficiente quanto P_w para encontrar soluções na fronteira pareto.

VIII. CONCLUSÃO

Este trabalho apresentou uma abordagem computacional para a definição de políticas de manutenção preventiva, aplicando conceitos de Teoria da Decisão, modelagem matemática e técnicas de otimização mono e multiobjetivo. A proposta foi aplicada a um conjunto de 500 equipamentos, utilizando dados reais e considerando diferentes planos de manutenção e modelos de falha baseados na distribuição de Weibull.

Foram desenvolvidos modelos que minimizam tanto o custo total de manutenção quanto o custo esperado de falha, por meio da formulação de funções objetivo adequadas. Para resolução dos modelos, utilizou-se o algoritmo GVNS com operadores de vizinhança adaptados ao problema. As abordagens multiobjetivo foram implementadas por meio das estratégias de soma ponderada e ε -restrita, sendo avaliadas com base no hipervolume das soluções obtidas.

Ao final do desenvolvimento, foi possível observar que o algoritmo GVNS, aliado às abordagens de otimização utilizadas, foi capaz de gerar soluções satisfatórias para o problema proposto. As análises demonstraram que ambas as

abordagens proporcionaram grande diversidade nas soluções e desempenho satisfatório em termos de hipervolume.

A realização deste trabalho contribuiu para o aprofundamento do conhecimento prático em técnicas de otimização aplicadas à área de manutenção, além de fortalecer a compreensão sobre os desafios e decisões envolvidas na construção de modelos computacionais voltados à engenharia.

REFERÊNCIAS

- [1] L. de Souza Batista, «Notas de aula da disciplina de Teoria da Decisão». 2025.